



Instituto Politécnico Nacional
Escuela Superior de Computo



Base de Datos

Ejercicio 4. Estado del arte: tres artículos científicos

P R E S E N T A

Espinosa Gómez David Enrique

Estrada Sanchez Emiliano

Mora Acosta Pablo

3CV2

A 09 de septiembre de 2026

Ejercicio 4. Estado del arte: tres artículos científicos

Ficha 1: Estructuras de índices aprendidos (ACM SIGMOD)

- **1. Cita en formato APA 7.^a edición:**

Kraska, T., Beutel, A., Chi, E. H., Dean, J., & Polyzotis, N. (2018). The case for learned index structures. En *Proceedings of the 2018 International Conference on Management of Data* (SIGMOD '18) (pp. 489–504). Association for Computing Machinery. <https://doi.org/10.1145/3183713.3196909>

- **2. Problema que aborda el artículo:**

Las estructuras tradicionales para acelerar búsquedas en bases de datos (como los árboles B+) asumen escenarios genéricos y no aprovechan la distribución real de la información, generando un consumo elevado de memoria y tiempos de respuesta mejorables.

- **3. Método o propuesta de los autores:**

Proponen reemplazar los índices clásicos por modelos matemáticos y de aprendizaje estadístico que aprenden los patrones de los datos, calculando de manera directa la posición física exacta en la que se encuentra guardado cada registro dentro del almacenamiento.

- **4. Resultado principal que reportan:**

Demuestran experimentalmente que los índices aprendidos logran superar la velocidad de búsqueda de las estructuras convencionales hasta en un 70%, reduciendo al mismo tiempo el espacio de memoria que ocupa el índice entre un 80% y un 90%.

- **5. Relación explícita con la Unidad Temática I:**

Se relaciona con el **Tema 6: Sistema gestor de bases de datos (componente gestor de almacenamiento)** y el **Tema 7: Arquitectura de tres niveles (nivel interno o físico e independencia física de datos)**, demostrando que es posible cambiar cómo se localizan los datos internamente sin alterar las consultas del usuario.

- **6. Aporte concreto para el proyecto del curso:**

Fundamenta por qué es indispensable declarar llaves primarias en los catálogos de materias y grupos dentro de PostgreSQL. Demuestra el impacto en memoria y tiempo de respuesta que tienen los índices automáticos para localizar rápidamente las ofertas académicas sin sobrecargar el sistema.

Ficha 2: Homologación e integración de entidades heterogéneas (ACM SIGMOD)

- **1. Cita en formato APA 7.ª edición:**

Mudgal, S., Li, H., Rekatsinas, T., Doan, A., Park, Y., Krishnan, G., Zheng, R., Paulsen, E., & Raghavendra, V. (2018). Deep learning for entity matching: A critical assessment. *En Proceedings of the 2018 International Conference on Management of Data (SIGMOD '18)* (pp. 169–184). Association for Computing Machinery.
<https://doi.org/10.1145/3183713.3196926>

- **2. Problema que aborda el artículo:**

La dificultad de identificar cuándo dos registros provenientes de listas distintas hacen referencia a la misma entidad real cuando existen errores tipográficos, abreviaturas o formatos de texto inconsistentes.

- **3. Método o propuesta de los autores:**

Diseñan un espacio de evaluación empírica sistemática donde comparan arquitecturas avanzadas de procesamiento de lenguaje natural frente a reglas tradicionales de comparación de cadenas, evaluando su capacidad para encontrar equivalencias semánticas entre registros desordenados.

- **4. Resultado principal que reportan:**

Los modelos de aprendizaje automático superan a los métodos clásicos hasta por 30 puntos porcentuales en tablas con datos ruidosos o abreviados, aunque demuestran que las reglas directas siguen siendo óptimas y más rápidas si la información ya viene limpia y estandarizada.

- **5. Relación explícita con la Unidad Temática I:**

Se vincula directamente con el **Tema 2: Características de una base de datos (integración y redundancia controlada)** y el **Tema 3: Archivos frente a bases de datos (inconsistencia)**, ilustrando las fallas derivadas de carecer de un catálogo único y centralizado.

- **6. Aporte concreto para el proyecto del curso:**

Aporta la justificación para consolidar las listas de profesores y asignaturas de ambos turnos. Permite estructurar un catálogo unificado donde materias registradas con nombres descriptivos se enlacen con su clave curricular correspondiente, evitando registros duplicados en el avance escolar.

Ficha 3: Optimización del motor relacional en PostgreSQL (ACM SIGMOD)

- **1. Cita en formato APA 7.^a edición:**

Marcus, R., Negi, P., Mao, H., Tatbul, N., Alizadeh, M., & Kraska, T. (2021). Bao: Making learned query optimization practical. En *Proceedings of the 2021 International Conference on Management of Data (SIGMOD '21)* (pp. 1275–1288). Association for Computing Machinery. <https://doi.org/10.1145/3448016.3452838>

- **2. Problema que aborda el artículo:**

La degradación en el rendimiento de los motores relacionales cuando el planificador de consultas comete errores de cálculo y selecciona caminos lentos para cruzar tablas vinculadas con múltiples condiciones.

- **3. Método o propuesta de los autores:**

Crearon una extensión conectada al optimizador nativo de PostgreSQL que aprovecha la experiencia de ejecuciones pasadas para orientar al motor hacia planes de búsqueda más eficientes, garantizando en todo momento la estabilidad y seguridad operativa del gestor.

- **4. Resultado principal que reportan:**

El sistema reduce los tiempos de respuesta hasta tres veces en comparación con el optimizador tradicional de PostgreSQL en cargas complejas, corrigiendo de manera autónoma las decisiones ineficientes del planificador clásico.

- **5. Relación explícita con la Unidad Temática I:**

Se relaciona con el **Tema 6: Sistema gestor de bases de datos (módulos componentes: procesador y optimizador de consultas)** y el **Tema 7: Arquitectura cliente-servidor**, explicando cómo el motor central del servidor atiende y resuelve las peticiones de datos.

- **6. Aporte concreto para el proyecto del curso:**

Brinda el fundamento sobre cómo el servidor PostgreSQL resuelve las búsquedas internas. Ayuda a plantear relaciones claras entre tablas (planes de estudio, docentes y horarios) para que el cálculo de promedios, avance académico y cupos responda con inmediatez.

Análisis comparativo y problema abierto

Los tres artículos analizados coinciden en que los métodos tradicionales de bases de datos, desarrollados bajo supuestos rígidos hace décadas, resultan insuficientes para las demandas actuales de velocidad, volumen y desorden en los datos. Kraska

et al. (2018), Mudgal et al. (2018) y Marcus et al. (2021) convergen en la incorporación de modelos adaptativos capaces de aprender de los propios patrones de la información para sustituir reglas estáticas por soluciones automáticas más rápidas y consistentes. Todos concuerdan en que manipular grandes volúmenes de datos con mecanismos improvisados sobrecarga al sistema de procesos manuales propensos a fallas.

A pesar de compartir esta base, difieren sustancialmente en la capa arquitectónica del sistema donde actúan:

- **Nivel físico y de almacenamiento:** Kraska et al. intervienen en el nivel más interno del sistema, redefiniendo las estructuras de indexación para ubicar la posición física de los registros en disco o memoria.
- **Nivel lógico y de integración:** Mudgal et al. se ubican en la etapa de homologación de datos, resolviendo discrepancias textuales entre registros antes de que sean incorporados al esquema de la base de datos.
- **Nivel del procesador y ejecución:** Marcus et al. operan en el núcleo del optimizador relacional (específicamente en PostgreSQL), mejorando las decisiones de búsqueda al cruzar tablas relacionadas.

A partir de estas lecturas, el **problema abierto** identificado es la tensión entre la adaptabilidad de los modelos automáticos y las garantías de predictibilidad indispensables en una base de datos. Mientras que las estructuras relacionales tradicionales garantizan tiempos máximos acotados y una estabilidad determinista bajo cualquier carga de trabajo, los modelos basados en aprendizaje pueden presentar variaciones inesperadas ante cambios repentinos de datos o exigir reentrenamientos costosos que saturan el equipo. El reto vigente consiste en diseñar sistemas híbridos que aprovechen la optimización adaptativa sin sacrificar la rigidez transaccional y la certeza formal que exige un gestor de bases de datos robusto.